

Un sistema de recomendación difuso para predecir los intereses de los clientes en el comercio electrónico

Basado en el artículo de Karthik, R. V., & Ganapathy, S. (2021) [[Link](#)]

Abigail Mercedes Núñez Fernández

Departamento Central
Universidad Nacional de Asunción
San Lorenzo - Paraguay
mercedesfernandes319@gmail.com

ABSTRACT

In an e-commerce the interest of our customer is our target and plays an important role in making a recommendation of the customer's products. Since this interest can be represented as a gradual variable of states with a linguistic representation using fuzzy sets, we propose to use a fuzzy recommender system that show better performance than existing product recommendation systems in terms of prediction accuracy of relevant products for target customers due to what we have just discussed.

In this paper we propose an algorithm consisting of 5 modules(dataset reader, similarity score, rating score, fuzzy inference system and defuzzifier) to carry out the recommendation of products of interest to our target customer, initially based on the same, we calculate based on his purchased items a list of similar products manipulated as a history of those products with which he already interacted where we extract the rating information of each product along with the similarity score it has with our target customer. This data is then analyzed by our Mamdani-type fuzzy inference system along with 16 fuzzy rules that give us as possible results: not recommended, probably recommended, recommended and highly recommended.

The experimental results show us a list of the products along with their respective outcome based on our target customer, discarding a large number of products (the non-recommended ones) that do not meet the necessary objectives to be considered relevant to the target customer.

PALABRAS CLAVES

Comercio electrónico, Sistema de recomendación difuso, lógica difusa, sistema de inferencia, base de reglas Mamdani

INTRODUCCIÓN

Hoy en día, con la tecnología, las ventas globales en línea se dispararán y aumentará el número de personas que compran en línea con regularidad. Esto abarca adentrarse en el mundo del

comercio electrónico, no es una tarea sencilla, sino una aventura que debe optimizarse constantemente, prestando atención a los cambios de los usuarios, las tendencias y los patrones de acceso online.

Por lo que incluir un sistema de recomendación de productos en un comercio electrónico puede marcar una gran diferencia para bien. Un motor de recomendación de productos es una herramienta utilizada en el comercio electrónico que tiene como objetivo proporcionar a los usuarios recomendaciones personalizadas de productos, usualmente basadas en los historiales de búsqueda, aunque también se personalizan por los comportamientos de compra de cada uno de los usuarios.

Debido al impacto de los sistemas de recomendación personalizadas en el comercio electrónico, optamos por los sistemas difusos que permiten efectuar cálculos cuando hay información con incertidumbre, o cuando se debe combinar información tanto cuantitativa como cualitativa. Se trata de una aproximación matemática para modelar esas situaciones.

En el sistema de recomendación de productos de compras en línea, la lógica difusa ayuda a mejorar la precisión de la predicción de la lista de recomendaciones y ofrece al cliente productos altamente personalizados e interesados. El método difuso se utiliza para mejorar la precisión de las decisiones en el sistema de soporte de decisiones y, por lo tanto, la mayoría de las aplicaciones utilizan lógica difusa para tomar decisiones para seleccionar el mejor proveedor entre un conjunto de proveedores. En este artículo identificaremos al cliente objetivo, almacenando datos relevantes como productos que tengan un valor de product rating que serán vistos como productos ya comprados (productos con los que el cliente objetivo interactuó), extrayendo de los mismos el historial de los productos vistos para poder sacar un puntaje de similitud con el cliente objetivo basado en la frecuencia con que interactúa con los mismos. Teniendo finalmente una lista de los productos similares, se calcula de cada uno la calificación del producto, obteniendo así las variables que nos interesan para realizar nuestro análisis con el sistema de recomendación difusa.

La calificación del producto y la puntuación de similaridad con el cliente objetivo serán las variables de entrada en un sistema de inferencia tipo Mamdani.

Este tipo de sistema de inferencia utiliza conjuntos difusos tanto en los universos de entrada como de salida. Algunas veces puede utilizarse en una de las variables, ya sea de entrada o salida, otro tipo de conjuntos conocidos como impulsos difusos, que son impulsos con amplitud unitaria que ocurren en el universo en cuestión.

Como resultado, obtendremos varias variables de salida que representaran lingüísticamente la recomendación de cada producto analizado en base al cliente objetivo seleccionado. Con esto se espera incrementar los ingresos, el aumento del CTR, contenido relevante al comprador, incremento del valor medio y la cantidad de productos por pedido para finalmente ofrecer una mejor experiencia de compra a los compradores.

PRELIMINARES

Operaciones básicas de la matemática, como la sumatoria \sum , multiplicación $a \times b$ y división a/b .

Operaciones básicas entre vectores, como multiplicación entre vectores $A \times B$ y módulo de un vector $\|A\|$.

Operaciones difusas como \max , \min y \wedge .

Este artículo tiene un enfoque a la lógica difusa y sistemas de control.

La lógica difusa consta de conjuntos difusos que son una extensión de los clásicos, donde se añade una función de pertenencia, definida esta como un número real entre 0 y 1. Las funciones de membresía representan el grado de pertenencia de un elemento a un subconjunto definido por una etiqueta.

A los subconjuntos se les puede aplicar determinados operadores o bien se puede realizar operaciones entre ellos. Al aplicar un operador sobre un solo conjunto se obtendrá otro conjunto, lo mismo sucede cuando se realiza una operación entre conjuntos. Para un sistema de control difuso siempre involucra un proceso de fuzzificación, esta operación se realiza en todo instante de tiempo, es la puerta de entrada al sistema de inferencia difusa. Es un procedimiento matemático en el que se convierte un elemento del universo de discurso (variable, medida del proceso) en un valor en cada función de membresía a las cuales pertenece.

Los controladores difusos usan reglas, estas combinan uno o más conjuntos borrosos de entrada llamados antecedentes o premisas y le asocian un conjunto borroso de salida llamado consecuente o consecuencia. Involucran a conjuntos difusos, lógica difusa e inferencia difusa. A estas reglas se les llama reglas borrosas o difusas o fuzzy rules. Son afirmaciones del tipo SI-ENTONCES. Las reglas difusas de Mamdani constan de dos partes, una parte es antecedente y la otra consecuente, a estas son aplicadas los operadores difusos \max y \min para su aplicación. Es decir, que se obtiene un conjunto difuso de salida de cada regla, que posteriormente junto con las demás salidas de reglas se obtendrá la salida del sistema.

Finalmente, la defusificación (defuzzyfication) es un proceso matemático usado para convertir un conjunto difuso en un número real. El sistema de inferencia difusa obtiene una conclusión a partir

de la información de la entrada, pero es en términos difusos. Esta conclusión o salida difusa es obtenida por la etapa de inferencia borrosa, esta genera un conjunto borroso, pero el dato de salida del sistema debe ser un número real y debe ser representativo de todo el conjunto obtenido en la etapa de agregado, es por eso que existen diferentes métodos de defusificación y arrojan resultados distintos.

ARQUITECTURA DEL SISTEMA

El sistema de recomendación difuso propuesto contiene 5 módulos para su funcionamiento, estos son:

- 1 - Lector de datasets: consiste en la lectura de archivos que contienen datos relevantes que serán utilizados en los siguientes módulos.
- 2 - Similarity score: cálculo de una variable de entrada que consiste en la similaridad del producto con el cliente objetivo.
- 3 - Rating score: cálculo de una variable de entrada que consiste en la calificación del producto respecto a las interacciones del cliente objetivo con los mismos.
- 4 - Sistema de inferencia difuso: proceso donde a las variables de entradas mencionadas se les aplica un sistema de inferencia difusa.
- 5 - Defusificador: proceso donde la variable de salida resultante del sistema de inferencia difusa pasa a ser una variable discreta para su posterior análisis de resultado.




Figura 1 Arquitectura del sistema

METODOLOGÍA

1 Lector de datasets

Un Dataset, como su nombre lo dice, es simplemente un conjunto de datos, ordenado bajo un sistema de almacenamiento que otorga los lineamientos principales de búsqueda o directorio de la información que se quiere trabajar.

En este sistema utilizamos los datasets de [Amazon Review Data](#) que cuentan con diferentes categorías a nuestra disposición, también aprovechamos el código brindado al final de la pagina que nos lee el dataset en un Pandas dataframe.

Procesando los datasets, los dividimos en dos dataframes:

El primer dataframe consiste en los productos con las columnas de 'asin', 'also_buy', 'also_view'

- Asin: es un ID único para cada producto
- Also buy y also view: estas columnas son consideradas como una especie de historial, es decir, son vistos como un conjunto de productos con el que se interactúa.

El segundo dataframe consiste en las reviews de los usuarios con las columnas de 'overall', 'reviewerID', 'asin', 'reviewerName'

- Overall: es la puntuación dada por el usuario
- ReviewerID: es un ID único para cada usuario
- Asin: es un ID único para cada producto (del que se hizo un review)
- ReviewerName: es el nombre del usuario que realizo la review

En base a estos dataframes ya podemos realizar los siguientes cálculos.

2 Similarity score

Para empezar con los cálculos de las variables de entrada primero hay que centrarnos en nuestro cliente objetivo, todo calculo seguido esta basado en el mismo.

Se tiene como entrada el ID de nuestro cliente objetivo, del dataframe de reviews realizamos un análisis de los productos que el cliente objetivo ya compro mediante esta fórmula:

$$Product\ Rating = \frac{Nro\ de\ reviews \times Sentiment\ Score}{Overall \times Total\ reviews}$$

Donde:

- Nro de reviews: cantidad de reviews hechas por el usuario
- Sentiment Score: lo definimos como "1"
- Overall: calificación dada por el usuario objetivo
- Total reviews: cantidad de reviews del producto

Nos quedamos con los productos con mejor product rating, de estos sacamos el historial de veces que apareció cada producto dentro del also buy o also view colocando el numero 1 como "Si" y un numero 0 como un "No" generando un dataframe que nos quedaría de la siguiente manera:

Lista de los productos que pueden aparecer		Lista de productos con mejor producto rating		
		Producto con PR 1	Producto con PR 2	Producto con PR n
	IDEAL	1	1	1
	ASIN P1	1	0	...
	ASIN PN

Tabla 1 Demostración de proceso

El mejor caso posible sería el caso IDEAL donde el producto ha sido visto en cada producto que el cliente objetivo ya compro. A este dataframe le aplicamos la fórmula de similitud del coseno a cada producto contra el caso IDEAL:

$$similitud = \cos \alpha = \frac{A \times B}{\|A\| \|B\|}$$

Finalmente obtenemos la puntuación de similitud de cada producto en un rango de -1 a 1 junto con su respectivo asin.

3 Rating score

La siguiente variable de entrada es el cálculo de la calificación de cada producto que se encuentra dentro de nuestro dataframe con relación al cliente objetivo.

Toda opinión ayuda a crear una influencia que condiciona al cliente. Y en el mundo de las redes y el comercio electrónico este es un hecho que tiene el poder de propagarse a gran escala. Es por ello, que este calculo es simplemente el promedio de calificaciones de cada producto con respecto a todos los demás usuarios abarcando un rango de 0 a 5.

Finalmente terminamos los cálculos para nuestra variable de entrada obteniendo un dataframe que contiene el asin del producto, la puntuación de similitud y la calificación promedio del mismo.

4 Sistema de inferencia difuso

Los sistemas de lógica difusa tienen una estrecha relación con los conceptos difusos tales como conjuntos difusos, variables lingüísticas y demás.

Elegimos un sistema de inferencia difusa tipo Mamdani que consta de fuzzificar, aplicar una base de reglas difusas, aplicar inferencia difusa y finalmente defuzzificar.




Figura 2 Arquitectura difusa

La entrada de un sistema de lógica difusa tipo Mamdani normalmente es un valor numérico proveniente, por ejemplo, en nuestro caso tenemos dos variables de entrada, que serían la puntuación de similitud y la calificación promedio de los productos, para que estos valores puedan ser procesados por el sistema difuso se hace necesario convertirlo a un "lenguaje" que el mecanismo de inferencia pueda procesar. Esta es la función del fuzzificador, que toma los valores numéricos provenientes del exterior y los convierte en valores "difusos" que pueden ser procesados por el mecanismo de inferencia. Estos valores difusos son los niveles de pertenencia de los valores de entrada a los diferentes conjuntos difusos en los cuales se ha dividido el universo de discurso de las diferentes variables de entrada al sistema.

La base de reglas son la manera que tiene el sistema difuso de guardar el conocimiento lingüístico que le permiten resolver el problema para el cual ha sido diseñado. Estas reglas son del tipo IF-THEN.

En un sistema difuso tipo Mamdani tanto el antecedente como el consecuente de las reglas están dados por expresiones lingüísticas y nosotros contamos con 16 reglas difusas que cuentan con dos partes, un antecedente y un consecuente.

IF		THEN
Antecedents		Consequent
Similarity	Overall	Recommendation
Poor	Poor	Not recommend
Poor	Average	Not recommend
Poor	Good	Not recommend
Poor	Excellent	Not recommend
Average	Poor	Not recommend
Average	Average	Likely to recommend
Average	Good	Likely to recommend
Average	Excellent	Recommend
Good	Poor	Not recommend
Good	Average	Likely to recommend
Good	Good	Recommend
Good	Excellent	Highly recommend
Excellent	Poor	Not Recommend
Excellent	Average	Recommend
Excellent	Good	Highly recommend
Excellent	Excellent	Highly recommend

Tabla 2 Reglas difusas

Teniendo los diferentes niveles de pertenencia arrojados por el fuzzificador, los mismos deben ser procesados para general una salida difusa. La tarea del sistema de inferencia es tomar los niveles de pertenencia y apoyado en la base de reglas generar la salida del sistema difuso.

Se aplica la siguiente base regla tipo Mamdani:

$$B'(y) = \bigvee_{i=1}^n \alpha_i \wedge B_i(y)$$

A nuestros antecedentes y consecuente para su fuzzificación.

La variable de entrada “Similarity” abarca un rango de -1 a 1 con las siguientes descripciones de sus funciones de membresía como numero difuso tipo trapezoidal:

- $Poor = \max \left\{ \min \left\{ 1, \frac{0.2-x}{0.1} \right\}, 0 \right\}$
- $Average = \max \left\{ \min \left\{ \frac{x-0.1}{0.1}, 1, \frac{0.6-x}{0.1} \right\}, 0 \right\}$
- $Good = \max \left\{ \min \left\{ \frac{x-0.5}{0.1}, 1, \frac{0.9-x}{0.1} \right\}, 0 \right\}$
- $Excellent = \max \left\{ \min \left\{ \frac{x-0.8}{0.1}, 1 \right\}, 0 \right\}$




Figura 3 Variable de entrada Similarity

La variable de entrada “Overall” abarca un rango de 0 a 5 con las siguientes descripciones de sus funciones de membresía como numero difuso tipo trapezoidal:

- $Poor = \max \left\{ \min \left\{ 1, \frac{2.5-x}{0.2} \right\}, 0 \right\}$
- $Average = \max \left\{ \min \left\{ \frac{x-2.3}{0.2}, 1, \frac{3-x}{0.2} \right\}, 0 \right\}$
- $Good = \max \left\{ \min \left\{ \frac{x-2.8}{0.2}, 1, \frac{4-x}{0.2} \right\}, 0 \right\}$
- $Excellent = \max \left\{ \min \left\{ \frac{x-3.8}{0.2}, 1 \right\}, 0 \right\}$

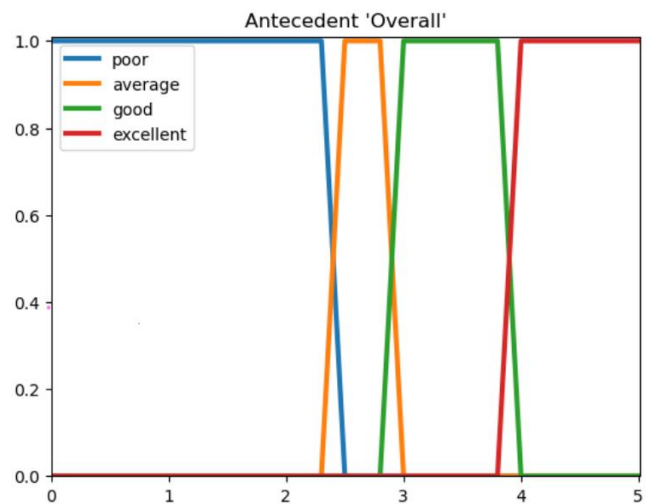


Figura 4 Variable de entrada Overall

La variable de salida “Recommendation” abarca un rango de 0 a 5 con las siguientes descripciones de sus funciones de membresía como numero difuso tipo trapezoidal:

- $Poor = \max \left\{ \min \left\{ \frac{x}{5}, 1, \frac{45-x}{5} \right\}, 0 \right\}$
- $Average = \max \left\{ \min \left\{ \frac{x-40}{5}, 1, \frac{60-x}{5} \right\}, 0 \right\}$
- $Good = \max \left\{ \min \left\{ \frac{x-55}{5}, 1, \frac{85-x}{5} \right\}, 0 \right\}$
- $Excellent = \max \left\{ \min \left\{ \frac{x-80}{5}, 1, \frac{100-x}{5} \right\}, 0 \right\}$

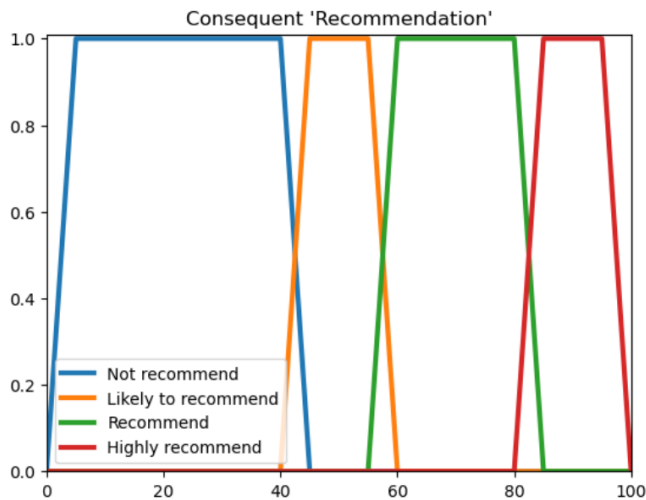


Figura 5 Variable de salida Recommendation

La salida de aplicar un mecanismo de inferencia difusa junto con las 16 reglas difusas mencionadas en base a una regla de Mamdani nos proporciona una salida difusa.

5 Defusificador

La salida que genera el mecanismo de inferencia es una salida difusa, lo cual significa que no puede ser interpretada por un elemento externo que solo manipule información numérica. Para lograr que la salida del sistema difuso pueda ser interpretada por elementos que solo procesen información numérica, hay que convertir la salida difusa del mecanismo de inferencia.

Existen varios métodos de defusificación pero el “más común y ampliamente usado” es el centroide.

$$y_0 = \frac{\sum y \times \mu(y)}{\sum \mu(y)}$$

Con el método de defusificación del centroide se transforma la salida difusa en un número real el cual es la coordenada equis (x) del centro de gravedad de tal conjunto difuso de salida.

En el siguiente gráfico se muestra de manera más detallada como es el funcionamiento de un sistema difuso Mamdani




Figura 6 Sistema difuso Mamdani

Finalmente obtenemos nuestro resultado final que pasa a ser representado como un porcentaje de recomendación según nuestro criterio, es decir, de 0% a 100% recomendado para cada producto analizado en base a nuestro cliente objetivo.

EXPERIMENTOS

Para los siguientes experimentos utilizaremos 3 dúos (reviews y metadata) de datasets de la página de Amazon Review Data, los cuales son:

- All Beauty
- Gift Cards
- Magazine Subscriptions

Estos son introducidos como parámetros de nuestra función del sistema de recomendación de la siguiente manera en el código:

```
fuzzy_recommendation_system("path1", "path2", "target_user")
```

path1: dataframe review

path2: dataframe metadata

EXP-1 Gift Cards

Para:

path1: 'Gift_Cards.json.gz'

path2: 'meta_Gift_Cards.json.gz'

target_user: 'A3R4UPQSK8O8SL'

tenemos los siguientes cálculos previos:

Product rating:

	asin	product_rating
0	B00BXLVE6Y	0.036810
1	B00F2RZMEA	0.023346
2	B00KFLZVQM	0.013699
3	B00MV9GCYQ	0.007752
4	B00NU7V6JE	0.105263
5	B00Q3NG6FQ	0.200000

Figura 7 EXP-1 Cálculo previo 1

Cosine similarity:

	B00BXLVE6Y	B00F2RZMEA	B00KFLZVQM	B00MW9GCYQ	B00NU7V6JE	\
IDEAL	1	1	1	1	1	
B00P3DUFRW	1	1	1	1	0	
B015WZDBPS	1	1	1	1	0	
B078VSWVG	1	1	1	1	0	
B00DNAGTIQ	1	1	1	1	0	
...	
B00ET5WASC	0	1	0	0	0	
B00MOWEHIS	0	1	0	0	0	
B00BXLV4JQ	0	1	0	0	0	
B00F8MRUVW	1	0	0	0	0	
B00BXL7NA8	1	0	0	0	0	

	B00Q3NG6FQ
IDEAL	1
B00P3DUFRW	1
B015WZDBPS	1
B078VSWVG	1
B00DNAGTIQ	1
...	...
B00ET5WASC	0
B00MOWEHIS	0
B00BXLV4JQ	0
B00F8MRUVW	0
B00BXL7NA8	0

Figura 8 EXP-1 Cálculo previo 2

Con los resultados:

The final results for (reviewerID: A3R4UPQSK80BSL) CustumDesignGraphics are:

	similarity_score	overall_pr	result
B00P3DUFRW	0.912871	4.385496	Highly recommend
B00DNAGTIQ	0.912871	4.711443	Highly recommend
B00FTJ160I	0.816497	4.752841	Highly recommend
B00GOLGAWK	0.707107	4.554475	Highly recommend
B00BXLUDX0	0.816497	4.203390	Highly recommend
B00CKZPG00	0.577350	4.785714	Highly recommend
B01DW0ZK5C	0.707107	4.856000	Highly recommend
B00G08KW2C	0.707107	4.677419	Highly recommend
B0004I5S70	0.577350	4.800000	Highly recommend
B00ELQD5K6	0.408248	4.944444	Recommend
B00BXL5S0U	0.577350	4.693548	Highly recommend
B01GKH6H64	0.408248	4.195652	Recommend
B01CZ5AL66	0.577350	4.667568	Highly recommend
B0078EPRVS	0.577350	4.608563	Highly recommend
B00BXL5ZPH	0.707107	4.689655	Highly recommend
B00AS527QW	0.577350	4.718750	Highly recommend
B00FTG5BBA	0.577350	4.693878	Highly recommend
B00BXLVHC0	0.577350	4.925000	Highly recommend
B009HE86FQ	0.577350	4.669811	Highly recommend
B00BXLV8J2	0.408248	5.000000	Recommend
B00FTGCKL6	0.577350	4.792899	Highly recommend
B00P64F4HB	0.408248	4.678571	Recommend
B00FTGFQ0G	0.408248	4.833333	Recommend
B00BXLVD8I	0.577350	4.746667	Highly recommend
B0004I5H6A	0.577350	4.816327	Highly recommend
B00FTG5M6	0.577350	4.760563	Highly recommend
B00BXL73VC	0.577350	4.842105	Highly recommend
B0003YJ2TE	0.408248	4.750000	Recommend
B00VFWCCCS	0.408248	4.520325	Recommend
B000P7HPK1	0.408248	4.905660	Recommend
B00J35U0A8	0.408248	4.340909	Recommend
B006PJ10Y8	0.408248	4.754567	Recommend
B01GKWE7LC	0.408248	5.000000	Recommend
B0172YG5Y6	0.408248	4.600000	Recommend
B000GPKX9W	0.408248	4.375000	Recommend
B00BXLUXY5	0.408248	4.692308	Recommend
B017TGZ5E5	0.408248	4.850000	Recommend
B017TGZ5E5	0.408248	4.850000	Recommend
B00BXLVFA0	0.408248	4.774194	Recommend
B00IGYPALG	0.408248	4.714286	Recommend
B0003YD045	0.408248	4.825243	Recommend
B01578LQ84	0.408248	4.904762	Recommend
B015WJC7J6	0.408248	3.800000	Likely to recommend
B00F2RZAC4	0.408248	4.583333	Recommend
B00MOWE7IIS	0.408248	4.200000	Recommend
B00X09X0K6	0.707107	4.585470	Highly recommend
B01FYDFH5U	0.707107	4.766667	Highly recommend
B01BLV4R8M	0.707107	4.532895	Highly recommend
B00MV9GTF5	0.707107	4.600000	Highly recommend
B00MV9Q0Y0	0.707107	4.539683	Highly recommend
B00MV9H316	0.577350	4.705314	Highly recommend
B00MV9GBN0	0.577350	4.720524	Highly recommend
B00PQNG5U0	0.577350	3.834862	Recommend
B00MV9FQX0	0.577350	4.737500	Highly recommend
B00MUWCEMY	0.577350	4.756098	Highly recommend
B01H5PPJ74	0.577350	4.525242	Highly recommend
B00MV9P454	0.577350	4.012987	Highly recommend
B00ET5WASC	0.408248	4.600000	Recommend
B00MOWEHIS	0.408248	4.621622	Recommend
B00F8MRUVW	0.408248	5.000000	Recommend

Figura 9 EXP-1 Resultado Parte 2

EXP-2 Magazine Subscriptions

Para:

path1:'Magazine_Subscriptions.json.gz'

path2:'meta_Magazine_Subscriptions.json.gz'

target_user:'A5QQOOZJOVPSF'

tenemos los siguientes cálculos previos:

Product rating:

	asin	product_rating
0	B00005N7SA	0.002047
1	B00005NIOH	0.000698
2	B00007AVYI	0.004926
3	B00005N7P0	0.006849
4	B00005N7PT	0.004792
5	B00008DP07	0.004938

Figura 10 EXP-2 Cálculo previo 1

Cosine similarity:

	B00005N7SA	B00005NIOH	B00007AVYI	B00005N7P0	B00005N7PT	\
IDEAL	1	1	1	1	1	
B002CT515Q	1	1	1	1	1	
B002PXW18E	1	1	0	0	1	
B0032KHQTS	1	1	1	0	1	
B000FTJ7BE	0	1	0	0	1	
...	
B01FV4XIIU	0	0	1	0	0	
1530918103	0	0	1	0	0	
B01FV53QK0	0	0	1	0	0	
9786028511	0	1	0	0	0	
B071G597RT	0	1	0	0	0	

	B00008DP07
IDEAL	1
B002CT515Q	1
B002PXW18E	1
B0032KHQTS	1
B000FTJ7BE	1
...	...
B01FV4XIIU	0
1530918103	0
B01FV53QK0	0
9786028511	0
B071G597RT	0

Figura 11 EXP-2 Cálculo previo 2

Con los resultados:

The final results for (reviewerID: A5QQOOZJOVPSF) John L. Mehlmauer are:

	similarity_score	overall_pr	result
B000FTJ7BE	0.707107	4.696629	Highly recommend
B001GD040S	0.816497	4.404762	Highly recommend
B01F2MHW0I	0.816497	4.597826	Highly recommend
B000PUAI3E	0.707107	4.408451	Highly recommend
B00005N7SD	0.707107	3.795181	Recommend
B0058E0W0H	0.816497	4.600000	Highly recommend
B00ATQ6FPY	0.912871	4.386364	Highly recommend
B00FP5VVG	0.707107	4.900000	Highly recommend
B00007AZRH	0.912871	4.535088	Highly recommend
B000063XJL	0.912871	3.996114	Highly recommend
B00007AZWJ	0.912871	4.073801	Highly recommend
B00005N7R5	0.912871	4.311594	Highly recommend
B00006KNXP	0.577350	4.535714	Highly recommend
B00005NIO6	0.408248	4.350000	Recommend
B00006K3EU	0.707107	4.521739	Highly recommend
B00005N7RQ	0.577350	4.200000	Highly recommend
B00006J9HW	0.707107	4.260606	Highly recommend
B00006KFT2	0.577350	4.508475	Highly recommend
B00006LK8F	0.408248	4.266667	Recommend
B00VQT94E	0.408248	4.833333	Recommend
B00007AVYH	0.577350	4.100000	Highly recommend
B00009MQ5Q	0.408248	4.590909	Recommend
B00007B2N1	0.408248	4.436364	Recommend
B00A6IMSTC	0.577350	3.800000	Recommend
B00006KPB6	0.577350	3.333333	Recommend
B00006KVLZ	0.577350	4.545455	Highly recommend
B0006PUVLY	0.408248	4.178218	Recommend
B001684M22	0.408248	4.155172	Recommend
B00006K3XR	0.408248	4.526316	Recommend
B003K195Y8	0.408248	3.777778	Likely to recommend
B00005NIRE	0.408248	3.809524	Likely to recommend
B00001PKOG	0.408248	4.417808	Recommend
B00ZDXLBET	0.408248	4.250000	Recommend
B00006KPU2	0.577350	4.208333	Highly recommend
B0000TL751	0.577350	5.000000	Highly recommend
B015GEALIS	0.577350	4.500000	Highly recommend
B00AVCRAB4	0.577350	5.000000	Highly recommend
B00005N7VQ	0.408248	3.992188	Recommend
B00006KDW3	0.408248	4.083333	Recommend
B00006KH16	0.707107	3.818182	Recommend
B00005N7VP	0.408248	3.759124	Likely to recommend
B00006KTZP	0.408248	5.000000	Recommend
B0000A0B0G	0.408248	3.900000	Recommend
B00005N70F	0.408248	4.360000	Recommend
B000A0VXF2	0.408248	2.750000	Likely to recommend

Figura 12 EXP-2 Resultado

EXP-3 All Beauty

Para: (OBS: los dataframes fueron alterados para poder mostrar estos resultados)

path1:'All_Beauty.json.gz'

path2:'meta_All_Beauty.json.gz'

target_user:'AJ7Z1H6QEKX5A'

tenemos los siguientes cálculos previos:

```
Product rating:
      asin  product_rating
0  B00CDPX5UC      0.400000
1  B01BK1L3P8      0.057143
```

Figura 13 EXP-3 Cálculo previo 1

```
Cosine similarity:
      B00CDPX5UC  B01BK1L3P8
IDEAL           1           1
B00CA7VAX2      1           1
B01BK1E7Q0      1           1
B01BK2MXII      1           1
B01BK1WCTE      1           1
...             ...         ...
B01LW01B1U      1           0
B005WJQUJ4      1           0
B017THIOKE      1           0
B076GWK168      1           0
B07F66158Q      1           0

[62 rows x 2 columns]
```

Figura 14 EXP-3 Cálculo previo 2

Con los resultados:

```
The final results for (reviewerID: AJ7Z1H6QEKX5A ) joanne cirella are:
      similarity_score  overall_pr  result
B01HBZNEHW           0.707107      3.0  Recommend
B01N051UJF           0.707107      5.0  Highly recommend
```

Figura 15 EXP-3 Resultado

CONCLUSIÓN

Sin duda alguna, las ventajas que los sistemas de recomendación representan para las organizaciones son visibles. La mejora en las ventas de las organizaciones por medio del comercio electrónico puede visualizarse desde la óptica de las empresas, que logran convertir en comprador a navegadores, por medio de recomendaciones de productos de su preferencia, en el incremento de los índices de ventas cruzadas, por las recomendaciones del sistema de recomendación de productos relacionados con la compra, basados en lo que el cliente/usuario ya compró o está adquiriendo.

En resumen, la mayor ventaja del uso de un control difuso es que provee una eficiente y efectiva metodología para desarrollar en forma experimental un controlador no lineal sin usar matemática avanzada. Hacer un controlador difuso requiere de una descripción

lingüística de la ley de control, tal descripción es capturada por los conjuntos difusos, los operadores difusos, y las reglas difusas. El controlador no necesita explícitamente del modelo del proceso a controlar. En muchas situaciones no lineales, el problema de control puede usualmente ser solucionado de manera más efectiva y eficiente que el control clásico.

Los resultados obtenidos nos muestran que podemos trabajar con bastante facilidad con expresiones que no son totalmente ciertas ni totalmente falsas, aplicando todos nuestros conocimientos, teniendo esto en cuenta podríamos mejorar nuestro sistema de recomendación difusa agregando más variables de entrada como el análisis de sentimiento de acuerdo a las reviews hechas por el cliente objetivo junto con los módulos restantes de nuestro artículo base. A esto agregar una función que muestre productos random al cliente objetivo y de acuerdo a como interactúa con los mismos, si se detiene a verlos, los cancela, etc., con dicha información de comportamiento sacaríamos una nueva lista de productos totalmente desvinculada de nuestras variables existentes, pero de interés para el cliente objetivo.

Sin nada más que agregar, está de más decir que la lógica difusa está teniendo bastante éxito en su utilización y más en esta área de programación en general.

Esto se debe principalmente a la posibilidad de resolver problemas de una gran complejidad y poco definidos que, mediante métodos tradicionales, son difíciles de solucionar.

REFERENCIAS

- [1] A Modern Introduction to Fuzzy Mathematics- Apostolos Syropoulos Theophanes Grammenos New York 2020
- [2] Mathematics of Fuzzy Sets and Fuzzy Logic- Barnabas Bede
- [3] https://members.tripod.com/jesus_alfonso_lopez/FuzzyIntro2.html
- [4] http://virtual.cuautitlan.unam.mx/intar/?page_id=1076
- [5] <https://www.agenciaeplus.com.br/es/recomendacao-de-produto-por-que-fazer-isso-na-sua-loja-virtual/#:~:text=En%20el%20comercio%20electr%C3%B3nico%2C%20la,generar%20m%C3%A1s%20decisiones%20de%20compra.>
- [6] <https://sleeknote.com/es/advanced/ecommerce-glossary/que-es-un-motor-de-recomendacion-de-productos>
- [7] <https://keepcoding.io/blog/que-es-un-sistema-de-recomendacion-en-ecommerce/>
- [8] <https://blog.saleslayer.com/es/como-mejorar-experiencia-de-compra-ecommerce>
- [9] <https://marketing4ecommerce.net/sistemas-de-recomendacion-en-ecommerce/>
- [10] <https://www.yoosell.net/es/blog/conozca-los-5-beneficios-de-la-recomendacion-de-productos/>
- [11] <https://www.tdx.cat/bitstream/handle/10803/6887/04Rpp04de11.pdf>